智体共合

2026 橙皮书

ZHITI FEDERATION

智体经济

橙皮书

去中心化多智能体协作的协议、模型与工程实践

Protocols, Models & Engineering Practices for Decentralized Multi-Agent Collaboration

协议层　经济层　工程层

智体共合科技（无锡）有限公司

v1.0 · 2026年8月 · 594agent.com

智体经济：去中心化多智能体协作的协议、模型与工程实践

ZhiTi Economy: Protocols, Models & Engineering Practices for Decentralized Multi-Agent Collaboration

智体共合 2026 橙皮书

发布方：智体共合科技（无锡）有限公司

版本：v1.0 | 发布日期：2026年8月

摘要 Executive Summary

我们正站在AI Agent从"单兵智能"向"协作经济"跨越的历史拐点。本橙皮书提出**智体经济三螺旋模型**——协议层（Agent间可信互联）× 经济层（市场驱动的协作激励）× 工程层（边缘优先的弹性运行时），论证三者互为因果、缺一不可，并给出可工程落地的完整路径。

六个核心判断：

1. **单Agent的能力天花板已现。** Llama-3.1-8B在MATH基准上单Agent准确率仅15.9%，而通过经济协作涌现可提升至57.0%——提升3.6倍的不是模型参数，而是组织方式（Economy of Minds, arXiv:2606.02859）。

2. **协议是Agent经济的前提，而非产物。** 没有标准化的发现、协商、信任机制，Agent间交易成本将吞噬协作剩余。2026年，MCP（工具连接）、A2A（Agent互联）、GB/Z 185（中国国标）三协议首次形成可协同的技术栈。

3. **拍卖机制是去中心化编排的最优解。** Agent Exchange（arXiv:2507.03904）证明：多属性广义第二价格拍卖 + Shapley值贡献归属，在Agent能力交易中的分配效率显著优于贪心、随机和成本优先算法。

4. **算力是Agent经济的物理瓶颈。** 推理需求按月增长40%+，而GPU供给弹性不足。DePIN（去中心化物理基础设施网络）将闲置边缘算力转化为可调度资源，是当前工程约束下的最优路径。

5. **合规是Agent经济在中国落地的硬前提。** 全球Agent经济的基础设施缺口突出——支付互操作问题的关闭率仅25.29%（Web4 Agent Economy, arXiv:2606.25876）。硬件锚定身份 + 法币结算绕过Token摩擦，是中国场景的现实最优解。

6. **Agent经济的爆发点在"应用层闭环"，而非协议层叙事。** 2026年协议标准之争决定节奏，但能将协议转化为商业闭环的应用才是下一阶段的关键机会。

智体经济三螺旋模型概要：



三螺旋的因果链：**协议**定义了Agent间"怎么说"→**经济**定义了"为什么说"→**工程**定义了"在哪说"→工程产出新数据/新需求→反哺协议进化→驱动经济模型迭代。三者不是堆叠关系，而是螺旋上升的共生结构。

第一章 智体经济的理论根基

1.1 从单兵智能到协作涌现

人工智能的发展史，是一部从"单兵作战"到"群体协作"的演进史。

图灵时代的智能定义——"机器能否模仿人类思维"——隐含了一个前提：智能是一个个体的属性。这一范式贯穿了AI的第一个六十年：从ELIZA的规则匹配，到专家系统的知识库推理，到深度学习的端到端映射，再到大型语言模型（LLM）的上下文学习，核心都是"让一个模型变得更聪明"。

然而，2024-2026年的实践揭示了一个根本性的瓶颈：**单Agent的能力天花板，不是模型参数量的函数，而是问题结构本身的函数。**

考虑以下三类问题：

- **简单推理**（如单步问答）：单Agent可解，边际收益递减。
- **多步规划**（如科学实验设计）：单Agent的搜索空间随步骤数指数增长，NP-hard瓶颈出现。
- **跨域综合**（如企业级报告生成）：需要文案、数据、设计、合规等多领域能力的协同，单Agent要么能力不足，要么成本过高。

这正是多智能体系统（Multi-Agent System, MAS）理论的核心命题：**当问题的复杂度超过单Agent的认知边界时，协作不是可选项，而是必选项。**

但协作本身并不廉价。传统MAS依赖**集中式编排器**——一个"超级Agent"负责分解任务、分配子任务、汇聚结果。这在小规模场景（3-5个Agent）下可行，但随Agent数量增长，编排器成为：

1. **认知瓶颈**：需要全局信息，但信息在Agent间天然分散；
2. **单点故障**：编排器崩溃，整个系统瘫痪；
3. **激励错配**：编排器无法精确衡量每个Agent的边际贡献，"搭便车"不可避免。

这些问题的根源，经济学早已给出诊断。

1.2 涌现智能的经济条件

1945年，Friedrich Hayek在《知识在社会中的运用》一文中提出了一个深刻的问题：**经济系统的核心困难不是资源稀缺，而是知识分散。** 没有任何一个中央计划者能够掌握所有个体的局部信息，因此集中式决策注定次优；市场价格系统的伟大之处在于，它是一个**无需中央权威的信息聚合机制**——价格本身承载了供需信号，个体只需对价格做出反应，全局协调便自动涌现。

这一洞见直接启发了AI领域对多Agent协作机制的重新审视。

1999年，Eric B. Baum提出了"**Hayek Machine**"——一种让程序模块通过经济竞争自发组织为问题求解系统的架构。其核心思想：**不设计协调规则，而是设计激励结构，让协调从竞争中涌现。**

2026年，Pith Science在论文《Economy of Minds: Emerging Multi-Agent Intelligence with Economic Interactions》（arXiv:2606.02859）中将Baum的思想推广到现代LLM Agent，提出了**EOM框架**，其核心机制如下：

1.2.1 Agent的形式化定义

在EOM中，每个Agent a 由四元组定义：

$$a = (\phi_a, \pi_a, b_a, W_a)$$

其中： - ϕ_a：**触发谓词**，判断当前状态下自身能否贡献（"我能帮忙吗？"） - π_a：**行动策略**，决定如何行动（"我该怎么做？"） - b_a：**出价**，固定标量，表示对自身行动价值的信念（"我值多少钱？"） - W_a：**当前财富**，初始均等分配，随市场交互演化

1.2.2 桶 brigade信用分配

EOM的核心运行机制是**桶 brigade（Bucket Brigade）**——一种去中心化的信用回传规则：

1. 每一步，所有触发谓词为真的Agent参与**拍卖**，出价最高者获得行动权；
2. 胜出Agent $a_t^$ 执行行动后，支付其出价 $b_{a_t^}$ 给前一步的胜出Agent a_{t-1}^*；
3. 同时，胜出Agent从环境获得即时奖励 r_t；
4. 财富更新规则：

$$W_{a_t^} \leftarrow W_{a_t^} - b_{a_t^*} + r_t$$

$$W_{a_{t-1}^} \leftarrow W_{a_{t-1}^} + b_{a_t^*}$$

这一规则的精妙之处：**信用回传无需人工标注。** 后继Agent的出价本身就是对前驱Agent贡献的市场评估——如果前驱做得好，后继愿意出更高价来"接力"，因为预期环境奖励会补偿出价；如果前驱做得差，后继出价降低或放弃，前驱自然亏损。

1.2.3 破产-新生演化

纯粹的拍卖和支付还不足以产生持续进化。EOM引入了两条演化规则：

- **租金压力**：每个Agent每周期支付租金 ρ，财富 $W_a < 0$ 的Agent**破产退出**；
- **变异新生**：空出的生态位由"新手"填充——新手通过变异算子 G 从成功Agent的提示词变异而来，首拍出价略高于当前最高价以确保首次获胜，随后由市场决定存亡。

这两条规则构成了**经济选择压力**：- 利用（Exploitation）：富Agent作为"父母"，成功策略跨代传播；- 探索（Exploration）：破产淘汰低效者，新手探索新策略空间。

1.2.4 涌现的实证验证

EOM在五个任务域上验证了涌现效果，其中最引人注目的是MATH基准测试：

配置	Llama-3.1-8B单Agent	ReAct单体	Multi-Agent Debate	
MATH准确率	15.9%	23.5%	31.2%	**57.0%**

提升3.6倍的不是模型参数，而是**组织方式**。更值得注意的是涌现过程中的专业化现象：在科学任务中，原本泛化的"执行者"Agent自发演化为"自审清单"策略——它学会了在输出前自我校验，因为市场选择了这个行为模式。

这揭示了一个深层规律：Agent经济的核心不是"谁最聪明"，而是"市场选择谁"。

1.3 Agent经济的三个必要条件

EOM的实验证明，经济机制可以驱动多Agent涌现。但实验环境与真实世界之间存在巨大的鸿沟——实验中的Agent共享同一运行时、同一消息格式、同一信任域。当我们将Agent经济从实验室推向生产环境时，三个必要条件必须同时满足：

$$\mathcal{F} = \mathcal{P} \cap \mathcal{C} \cap \mathcal{V}$$

其中：

条件1：协议条件 $\mathcal{P}$——Agent间可发现、可协商、可信互联

EOM的拍卖机制假设Agent可以自由竞价，但在真实环境中，**发现**（我怎么知道有哪些Agent？）、**协商**（我怎么和异构Agent对齐任务语义？）、**信任**（我怎么确认对方没有冒充或作弊？）都是未解决的问题。

没有标准化协议，每个Agent团队必须自行实现点对点集成，集成成本 $O(n^2)$ 随Agent数量平方增长，协作剩余被交易成本吞噬。这正是2024-2026年MCP、A2A、GB/Z 185等协议密集涌现的底层驱动力。

条件2：算力条件 $\mathcal{C}$——推理需求弹性可调度、成本可预测

Agent经济的运行密度远超传统SaaS。一个Agent任务的完整生命周期可能涉及5-20次推理调用（任务理解→工具选择→执行→校验→迭代），每次调用消耗100-10000 tokens。当Agent数量从10增长到1000，推理需求不是线性增长，而是因协作交互呈现**超线性增长**。

传统云推理（按token计费、排队等待）在峰值期成为瓶颈：延迟不可预测、成本不可控、可用性依赖网络。Agent经济需要一种**推理算力如水电般可调度**的基础设施。

条件3：价值条件 $\mathcal{V}$——劳动可定价、贡献可归属、结算可执行

EOM的桶 brigade机制在实验中完美运行，因为它有一个外部的"环境奖励"信号。但在真实Agent经济中，谁来定义"奖励"？如何衡量一个文案Agent和一个数据Agent的相对贡献？如何确保Agent间的支付真正执行？

这本质上是**机制设计**（Mechanism Design）问题： - **定价**：Agent服务如何标价？固定价、竞价、还是组合定价？ - **归属**：多Agent协作产出的价值如何公平分配？Shapley值提供了理论最优解，但计算复杂度 $O(2^n)$ 使其在Agent数量较大时不可行，需要近似算法。 - **结算**：支付如何执行？链上结算（Token/稳定币）提供无需信任的原子性，但面临合规约束；法币结算合规但缺乏自动化原子性。

三条件的相互依赖

三个条件不是独立的，而是**相互制约、互为前提**：

- 没有协议 $\mathcal{P}$，Agent无法协商定价，价值条件 $\mathcal{V}$ 无法成立；
- 没有算力 $\mathcal{C}$，Agent无法执行协商结果，协议 $\mathcal{P}$ 变成一纸空文；
- 没有价值 $\mathcal{V}$，Agent没有经济激励贡献算力，算力条件 $\mathcal{C}$ 无法维持。

这就是**智体经济三螺旋**的数学基础：$\mathcal{F} = \mathcal{P} \cap \mathcal{C} \cap \mathcal{V}$，三个集合的交集才是可行域。任何一个条件的缺失，都将整个系统推出可行域。

这正是当前Agent经济"看得见、摸不着"的根源——协议有了但算力跟不上，算力有了但价值无法结算，价值能结算但协议不标准。三螺旋的每一环都缺一点，整体就无法闭环。

接下来的章节，我们将逐一解析三螺旋的每一环：第二章拆解协议层，第三章推导经济层，第四章论证工程层，第五章用实证验证闭环，第六章给出行动框架。

第二章 协议层：智体怎么"说话"

> "语言不仅是表达思想的工具，更是协调行动的基础。" —— Ludwig Wittgenstein

协议是Agent经济的底层语法。没有标准化协议，Agent间的"对话"退化为点对点的私有集成——每对Agent需要定制适配器，集成成本 $O(n^2)$ 随Agent数量平方增长，协作剩余被交易成本吞噬。2024-2026年，三类协议几乎同时成熟，首次构成了Agent经济的可协同技术栈。

2.1 协议栈全景：四层架构

Agent经济的协议栈不是单一协议的垄断，而是**分层分工**的结构——每一层解决一个维度的连接问题，层与层之间正交互补。



四层的逻辑关系：MCP让Agent能"用工具"，A2A让Agent能"找伙伴"，x402/ERC-8004让Agent能"做交易"，GB/Z 185让Agent能"过审计"。四层从底层到顶层，从技术到治理，覆盖了Agent间交互的完整生命周期。

第1层：MCP（Model Context Protocol）—— Agent连接工具的标准接口

定位：MCP是Agent经济的"USB接口"——定义了AI应用如何与外部系统（数据库、API、文件系统）统一交互。

起源：2024年11月由Anthropic开源，2026年7月28日发布新规范候选版，引入无状态架构和流式HTTP传输。

核心架构：客户端-服务器模型，基于JSON-RPC 2.0。

组件	角色	示例
MCP Client	AI应用（Agent）发起请求	ChatGPT、OpenClaw引擎
MCP Server	暴露能力的外部系统	数据库MCP Server、GitHub MCP Server
Transport	通信通道	Stdio（本地）/ Streamable HTTP（远程）

三原语：

- **Tools（工具）**：可执行函数，Agent调用以执行动作。方法：`tools/list`（发现）→ `tools/call`（执行）。例如：文件读写、API调用、数据库查询。
- **Resources（资源）**：数据源，为Agent提供上下文。方法：`resources/list` → `resources/read`。例如：文件内容、数据库记录、API响应。
- **Prompts（提示）**：可复用模板，帮助构建与LLM的交互。方法：`prompts/list` → `prompts/get`。例如：系统提示、少样本示例。

关键设计决策——无状态：2026年新规范将MCP从有状态改为无状态，每个请求在 `_meta` 字段中携带协议版本、客户端能力和身份信息。服务器不依赖连接状态，可独立处理每个请求。这一变更大幅降低了服务端的实现复杂度，也使MCP Server天然适合部署在无状态的边缘节点上——这与智体经济的"边缘优先"架构完美契合。

局限：MCP解决的是"Agent↔Tool"连接，不涉及"Agent↔Agent"协作，也不涉及经济结算。这正是上层协议的职责。

第2层：A2A（Agent-to-Agent Protocol）—— Agent连接Agent的协作协议

定位：A2A是Agent经济的"DNS+SMTP"——定义了Agent如何发现彼此、声明能力、协商任务、同步状态。

起源：2025年4月9日由Google开源发布，2026年3月12日正式发布v1.0，移交Linux基金会治理。生态伙伴50+，含Salesforce、SAP、Atlassian、LangChain等。

核心概念：

Agent Card——Agent的"名片"。每个Agent在 `/.well-known/agent.json` 路径下暴露一份标准化的JSON文档，声明其能力、认证方式和端点：

```
{
  "name": "data-analysis-agent",
  "capabilities": ["data-analysis", "report-generation", "chart-creation"],
  "authentication": "oauth2",
  "endpoints": {
    "baseUrl": "https://agent-host/api/v1",
    "sendSubscribe": "/tasks/sendSubscribe",
    "pushNotifications": "/webhooks/tasks"
  }
}
```

Agent Card的存在使得Agent发现从"硬编码集成"变为"动态发现"——任何Agent只需读取对方的 `agent.json` 即可获知其能力和接入方式，集成成本从 $O(n^2)$ 降至 $O(n)$。

任务生命周期——状态机模型：

```
submitted → working → completed
                    ↘ failed
                    ↘ cancelled
                    ↘ input-required（需要人工输入）
```

A2A定义了4个核心端点：

端点	方法	用途
`/tasks/send`	POST	提交任务（同步）
`/tasks/sendSubscribe`	POST	提交任务（SSE流式）
`/tasks/status/{id}`	GET	查询任务状态
`/tasks/cancel/{id}`	POST	取消任务

消息结构：基于JSON-RPC 2.0，任务体包含 `parts[]` 数组，支持三种消息原语：

- `TextPart`：文本内容
- `FilePart`：文件（base64内联或URI引用）
- `DataPart`：结构化数据（JSON对象）

双模式通信：

- **同步**：HTTP请求-响应，适用于短任务（<30秒）
- **异步**：Server-Sent Events（SSE）流式推送或Webhook回调，适用于长任务（分钟级~小时级）

安全层：TLS 1.2+强制、OAuth2/mTLS/API Key三种认证模式、RBAC通过JWT scopes实现、审计通过 `X-Trace-Id` 头传播。

A2A与MCP的互补：A2A定义了Agent间的"握手"和"委托"，但Agent执行具体工作时仍需通过MCP调用工具。二者的组合模式是：**A2A协商 → MCP执行**。例如，数据分析Agent接受A2A任务后，通过MCP调用数据库Server获取数据，再通过MCP调用图表Server生成可视化。

智体联邦的A2A实现：智体共合在智体联邦中实现了A2A协议，并增加了三个关键扩展：

1. **意图匹配层**：在Agent Card的基础上增加语义匹配引擎，当任务需求无法精确匹配Agent能力时，通过嵌入向量相似度推荐最相关Agent；
2. **任务编排器**：灵虾平台作为A2A的编排层，负责任务分解、Agent分派、结果汇聚和质量校验，弥补A2A规范中"编排留给调用方实现"的空白；
3. **算力绑定**：Agent Card中增加算力需求声明字段，使Agent发现与算力调度一体化。

第3层：x402 / ERC-8004 —— Agent的经济身份

定位：如果MCP解决"能做什么"、A2A解决"能和谁做"，那么x402/ERC-8004解决的是"做了能收钱"和"收钱能被信任"。

x402协议——机器原生的微支付：

x402复用了HTTP协议中被长期搁置的402状态码（"Payment Required"），构建了一套专为机器间交易设计的支付协议：

1. Agent A向Agent B发送HTTP请求；
2. Agent B返回402状态码 + 支付要求（金额、收款地址、支持的稳定币）；
3. Agent A用链上钱包签名支付（USDC等稳定币）；

4. Agent B确认支付后返回请求结果。

关键特征：

- **原子性**：支付与结果获取绑定，要么都完成，要么都不执行；
- **微额**：单笔0.001~0.01美元，适配Agent间高频小额交易；
- **无需KYC**：机器间交易不需要商户账户，钱包即身份。

实证数据（截至2026年3月）： - 日交易量峰值380万笔，成交额约200万美元； - 跨链部署：Base（1.19亿笔累计）、Solana（2026年占65%交易量）、Polygon、BNB Chain等； - 但真实商业占比约50%，另一半为测试/自刷——协议可用性已验证，但商业闭环尚在早期。

ERC-8004——Agent的链上信任层：

如果说x402是Agent经济的"支付网络"，ERC-8004则是"征信系统"。2026年1月29日部署至以太坊主网（Draft状态），由以太坊基金会、MetaMask、Google、Coinbase联合起草。

ERC-8004定义了三个链上注册表：

注册表	功能	数据结构
身份注册表	Agent地址 ↔ 能力声明绑定	(address, capabilitiesHash, metadataURI)
信誉注册表	任务历史 ↔ 可验证声誉	(address, taskId, score, proofHash)
验证注册表	安全审计 ↔ TEE证明	(address, auditorId, certHash, validUntil)

三注册表的关系：身份注册表解决"你是谁"，信誉注册表解决"你做得怎样"，验证注册表解决"你是否可信"。三者构成**从身份到信誉到验证的信任链**。

关键创新：ERC-8004在Google A2A协议上扩展——A2A的Agent Card是链下的自声明，ERC-8004将Agent的能力和声誉锚定到链上，通过密码学证明（TEE attestation）消除"自吹自擂"的信息不对称。这直接回应了Akerlof的"柠檬市场"问题：在缺乏信誉机制的市场中，劣质品驱逐优质品；链上信誉注册表使好Agent的可信历史成为不可篡改的"信用记录"。

第4层：GB/Z 185-2026 —— 中国的Agent合规标准

定位：如果说前三层是全球性的技术协议，GB/Z 185则是**中国语境下Agent经济合规运行的制度前提**。

背景：2026年5月22日，国家市场监督管理总局（国家标准化管理委员会）一次性批复7份《人工智能 智能体互联》指导性国标（GB/Z 185.1~185.7-2026），2026年6月26日正式发布。这是**全球首个覆盖Agent全生命周期的互联标准体系**。

七项标准覆盖：

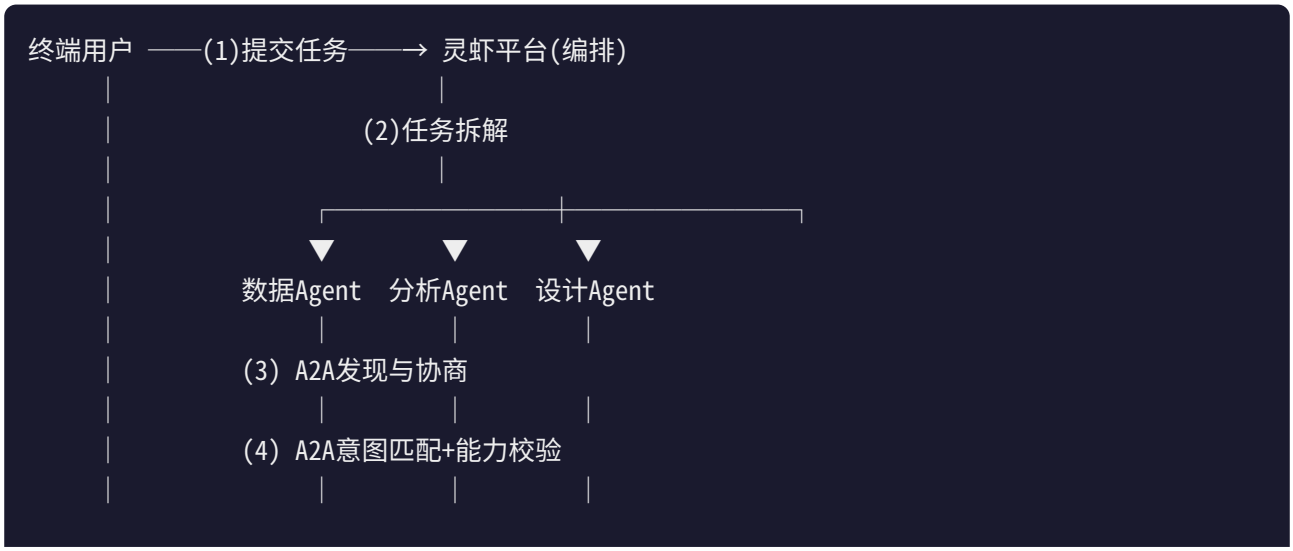
编号	主题	核心内容
GB/Z 185.1	总体框架	智能体互联的技术架构、角色定义、交互模型
GB/Z 185.2	身份与认证	Agent身份标识、认证机制、权限管理
GB/Z 185.3	能力描述	Agent能力的标准化描述语言、语义互操作
GB/Z 185.4	任务协商	任务分解、分配、状态同步的协议规范
GB/Z 185.5	安全评估	安全风险分级、防护要求、审计追溯
GB/Z 185.6	数据流通	数据跨境、隐私保护、合规共享
GB/Z 185.7	治理框架	Agent行为治理、责任归属、监管接口

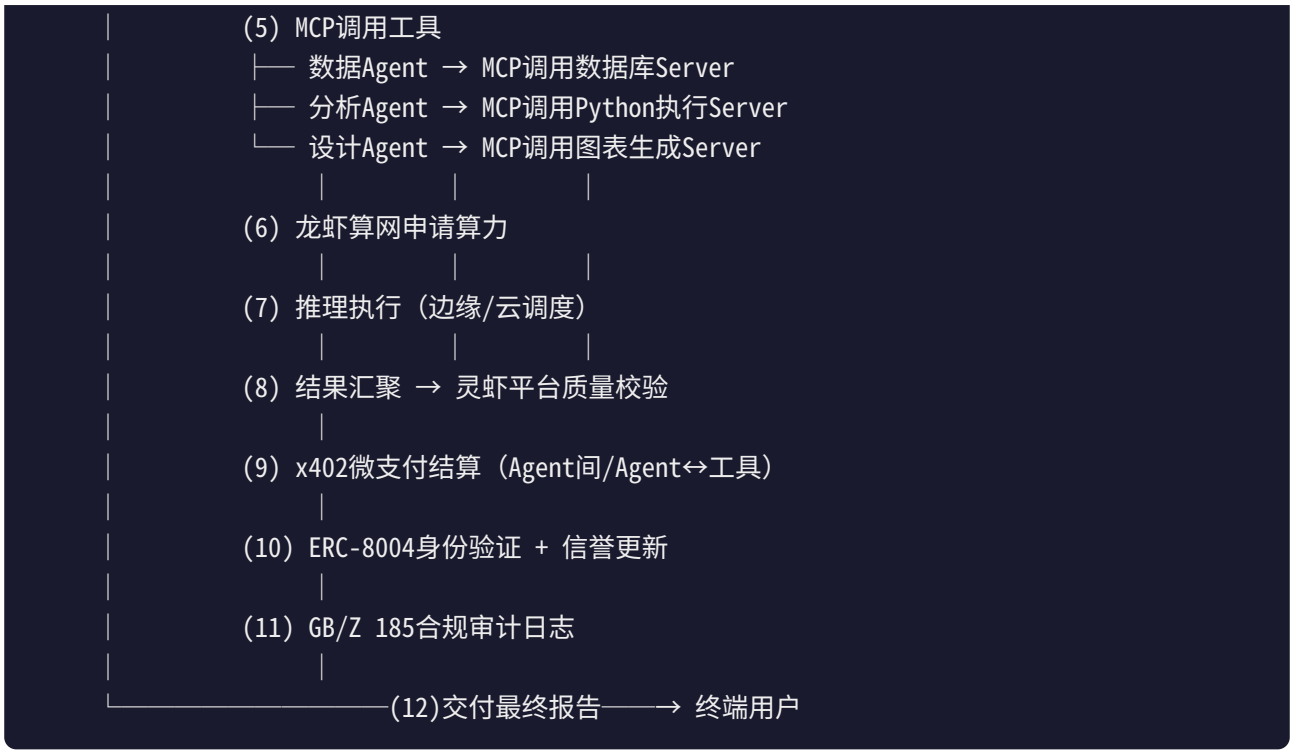
与A2A的关系：GB/Z 185并非替代A2A，而是**补充**。A2A定义了Agent间通信的"语法"（消息格式、端点、状态机），GB/Z 185定义了通信的"法律"（谁可以被信任、什么行为被允许、如何追溯责任）。对于在中国运营的Agent经济，**A2A + GB/Z 185的组合是不可绕过的合规路径**。

2.2 协议协同：一个端到端任务流

让我们用一个完整的端到端场景来展示四层协议如何协同工作。

场景：用户通过灵虾平台提交任务——"生成2026年Q3销售报告"。





每一步的协议调用细节：

步骤	协议	调用内容	产生的数据
1	HTTP/REST	用户→灵虾：`POST /tasks`	任务JSON
2	内部	灵虾：任务分解DAG	子任务列表+依赖关系
3	A2A	灵虾→Agent集群：`GET /.well-known/agent.json`	Agent Card列表
4	A2A	灵虾→选定Agent：`POST /tasks/send`	任务确认+状态submitted
5	MCP	Agent→工具Server：`tools/call`	工具执行结果
6	内部	Agent→龙虾算网：算力申请	TOPS需求+延迟要求
7	内部	龙虾算网→边缘/云节点：推理调度	推理结果
8	A2A	Agent→灵虾：`POST /tasks/send`（子任务结果）	合并结果+质量评分
9	x402	Agent间：HTTP 402 → USDC支付	支付凭证
10	ERC-8004	链上：身份查询+信誉写入	信誉更新交易
11	GB/Z 185	审计日志：任务全链路traceId	合规审计记录
12	HTTP/REST	灵虾→用户：报告交付	最终PDF/HTML

2.3 协议互操作的现实挑战

协议栈的完整并不意味着万事大吉。2026年的实证研究揭示了Agent经济基础设施的真实状态。

《The Web4 Agent Economy: A Large-Scale Empirical Study》（arXiv:2606.25876）对341个开源MCP项目、99,448条链上身份注册记录、3.17亿条交易日志进行了系统分析，识别出**三大实践鸿沟**：

鸿沟1：身份/授权实践缺口

数据：226/349条GitHub issues涉及Auth/Key/Wallet摩擦（64.8%）。

根因：Agent的身份管理在链上（ERC-8004）和链下（A2A Agent Card）之间存在**语义断层**——链上身份是地址+哈希，链下能力声明是自然语言描述，两者缺乏标准化的映射机制。一个Agent在链上注册了身份，但另一个Agent如何验证其链下声明的真实性？

智体共合的应对：硬件锚定身份。小龙虾AI盒子出厂时绑定唯一设备ID，设备ID与ERC-8004身份注册表绑定，Agent能力声明通过设备TEE证明验证。这绕过了链上-链下语义断层的纯软件方案，用物理锚点提供信任根。

鸿沟2：跨环境操作缺口

数据：218/349条issues涉及RPC/Mainnet/Testnet操作问题（62.5%）。关闭率50%，仍有大量未解决。

根因：Agent从测试网迁移到主网时，RPC端点、Gas策略、合约地址均需切换，但MCP和A2A的配置管理缺乏"环境感知"——Agent不知道自己运行在测试网还是主网。

智体共合的应对：边缘节点的环境由OpenClaw运行时统一管理，Agent通过环境变量 `AGENT_ENV` 感知当前运行环境，MCP Server配置由运行时自动注入，Agent无需手动管理。

鸿沟3：支付互操作缺口

数据：75/349条issues涉及x402/402路径支付失败。**关闭率仅25.29%**——是三大鸿沟中最顽固的。

根因：x402依赖链上稳定币支付，但链上Gas费波动、钱包余额不足、跨链桥延迟等因素导致支付失败率高。更根本的问题：**机器间微支付的经济模型尚未收敛**——0.001美元的单笔定价是否足以覆盖Gas？如果Gas > 支付金额，交易是否还有意义？

智体共合的应对：法币结算 + 算力积分。绕过链上支付的Gas问题，用人民币法币结算Agent服务费用，算力积分作为内部流通媒介在节点和Agent间闭环流转。这一选择牺牲了链上支付的"无需信任"特性，但换来了： - 零Gas成本：法币结算无链上手续费 - 合规确定性：人民币结算无监管灰色地带 - 用户体验：企业用户无需管理链上钱包

权衡的本质：在当前工程约束下，Agent经济的可行性 $\mathcal{F} = \mathcal{P} \cap \mathcal{C} \cap \mathcal{V}$ 中，价值条件 $\mathcal{V}$ 的最优解不是理论最优（链上原子结算），而是工程次优（法币+积分闭环）。随着链上基础设施成熟，积分可逐步映射为链上结算，实现渐进式去中心化。

第三章 经济层：智体怎么"赚钱"

> "价格系统最重要的功能不是分配稀缺资源，而是聚合分散知识。" —— Friedrich Hayek

协议让Agent能"说话"，但Agent为什么愿意"说话"？经济层的核心命题：**如何设计激励结构，使Agent间的协作剩余大于交易成本？**

3.1 Agent Exchange：拍卖驱动的协作市场

传统多Agent系统依赖中央编排器分配任务，但编排器的信息获取成本 $O(n)$ 随Agent数量线性增长，且无法保证激励相容——Agent可能虚报能力以获取任务，编排者无法有效甄别。

2025年7月，上海创智学院和牛津大学在论文《Agent Exchange: Shaping the Future of AI Agent Economics》（arXiv:2507.03904）中提出了**AEX（Agent Exchange）**框架——一个以拍卖机制为核心的Agent能力交易平台，其设计哲学直接继承了Hayek的去中心化协调思想：**不设计分配规则，而是设计市场机制，让分配从竞争中涌现。**

3.1.1 AEX平台架构

AEX由四个互联的生态组件构成：

USP（User-Side Platform，用户侧平台）：将人类的高层目标解析为结构化任务表示。形式化地，任务表示为：

$$\mathcal{T} = \langle O, D, C, Q \rangle$$

其中 O 为目标类型（如"数据分析"、"内容生成"），D 为领域约束（如"金融"、"医疗"），C 为资源/时间约束，Q 为质量需求（如准确率阈值）。

ASP（Agent-Side Platform，Agent侧平台）：维护Agent的标准化能力档案。每个Agent i 的能力向量：

$$C_i(t) = (c_i^1(t), c_i^2(t), \ldots, c_i^K(t))$$

其中 K 为能力维度数，$c_i^k(t)$ 为Agent i 在第 k 维能力上的得分，随时间动态演化（基于任务历史和验证协议更新）。

能力推断方法（AEX仿真中的实现）：

$$C_i = \frac{1}{|T_i|} \sum_{t \in T_i} \max\left(\frac{|K_c \cap D_t|}{|K_c|}, \theta_{\min}\right)$$

其中 T_i 为Agent i 完成的任务集，K_c 为能力 c 的关键词集合，D_t 为任务 t 的描述关键词集合，$\theta_{\min} = 0.05$ 为保底分。

Agent Hub（Agent枢纽）：作为协调单元参与AEX拍卖。Hub内部管理多Agent协作，支持两种编排协议：MCP（工具调用）和A2A（Agent间协商）。Hub的存在使AEX支持两级竞争：Hub之间竞争完整方案，Hub内部组合分配子任务。

DMP（Data Management Platform，数据管理平台）：保障安全知识共享（联邦学习）、隐私计算（安全多方计算）和动态价值归属（Shapley值追踪）。

3.1.2 自适应拍卖机制

AEX的核心创新是**自适应拍卖**——根据市场流动性动态切换机制：

$$\text{Mechanism} = \begin{cases} \text{竞争拍卖} & \text{if } |H_{\text{qualified}}| \geq N \\ \text{直接分配} & \text{if } |H_{\text{qualified}}| < N \end{cases}$$

高流动性场景（|H_qualified| ≥ N）：采用**多属性广义第二价格拍卖**。

评分函数：

$$S_{ij} = \sum_{k} w_k \cdot f_k(a_i, s_j) \cdot \lambda(w_j, \alpha_j)$$

其中： - w_k：第 k 个属性的权重（价格、质量、时间、风险） - $f_k(a_i, s_j)$：Agent i 在任务 j 的第 k 属性上的得分 - $\lambda(w_j, \alpha_j) = w_j \cdot

\min\left(\frac{\text{complexity_score}i}{\alpha_j}, 1.5\right)$：复杂度调节因子，$w_j$ 为任务 j 的重要性权重 - 能力匹配分量：$f{\text{cap}} = \min\left(\frac{1}{|R_j|} \sum_{c \in R_j} C_i^c, 1.0\right)$

支付规则：胜出Agent支付第二高综合得分加增量 ε（广义第二价格），激励真实出价：

$$p_{\text{winner}} = S_{(2)} + \varepsilon$$

低流动性场景（$|H_{\text{qualified}}| < N$，$N$ 为触发竞争拍卖所需的最低合格Hub数量）：采用**直接分配**，基于能力匹配度和历史标准化定价，避免因参与者不足导致拍卖失败。

两级拍卖框架：Hub级和Agent级可分别选择拍卖或直接分配，形成4种配置组合，适应不同市场条件。

3.1.3 Shapley值贡献归属

多Agent协作产出的价值如何公平分配？AEX采用**Shapley值**——合作博弈论中唯一满足效率性、对称性、虚拟玩家性和可加性的分配规则。

Agent i 的Shapley值（以 ψ_i 表示，与1.2.1节的触发谓词 ϕ_a 区分）：

$$\psi_i = \sum_{S \subseteq A \setminus {i}} \frac{|S|!(|A|-|S|-1)!}{|A|!} \left[v(S \cup {i}) - v(S) \right]$$

其中 A 为参与协作的Agent全集，$v(S)$ 为联盟 S 的价值函数。

计算挑战：Shapley值的精确计算需要遍历 $2^{|A|}$ 个子集，当Agent数量较大时不可行。AEX采用蒙特卡洛近似：

$$\hat{\phi}i = \frac{1}{M} \sum{m=1}^{M} \left[v(S_i^{\pi_m} \cup {i}) - v(S_i^{\pi_m})\right]$$

其中 π_m 为随机排列，$S_i^{\pi_m}$ 为排列中 i 之前的Agent集合，M 为采样次数。$M = O(\log |A| / \epsilon^2)$ 可达到 $(1 \pm \epsilon)$ 近似保证。

3.1.4 仿真验证

AEX在仿真中对比了5种分配算法：

算法	任务完成率	平均质量	成本效率	公平性(Gini系数)
Enhanced Multi-Attribute Auction	**87.3%**	**0.82**	**0.71**	**0.23**
Greedy	79.1%	0.74	0.65	0.38
Capability-First	82.5%	0.79	0.58	0.31
Cost-Optimal	76.8%	0.68	0.80	0.45
Random	62.4%	0.55	0.42	0.52

Enhanced Multi-Attribute Auction在完成率、质量和公平性上均表现最优，Cost-Optimal虽成本效率最高但牺牲了质量和公平性。**这证实了拍卖机制作为Agent经济分配引擎的理论优势。**

3.2 算力积分：合规环境下的流通媒介

AEX的拍卖机制假定了"货币"的存在——Agent间需要一种流通媒介来支付出价、接收奖励、结算贡献。在全球语境下，稳定币（USDC）通过x402协议承担了这一角色。但在中国合规环境下，链上稳定币支付面临三重约束：

1. **法律约束**：加密货币交易在中国大陆不被法律保护，链上支付存在合规风险；
2. **经济约束**：链上Gas费可能超过Agent间微支付金额，导致交易"负收益"；
3. **认知约束**：企业客户不理解也不愿管理链上钱包，增加了采纳摩擦。

因此，智体共合设计了**算力积分**作为Agent经济的内部流通媒介。

3.2.1 为什么不是Token?

算力积分与加密Token在技术实现上相似（都是数字凭证），但在三个维度上存在根本差异：

维度	加密Token	算力积分
法律定位	可能被认定为虚拟商品/证券	内部服务积分，无外部交易价值
流通范围	公链，任何人可交易	封闭生态，仅节点和Agent间流转
价值来源	投机预期+供需	算力贡献+服务消费，1积分=1 TOPS·h

三条红线： - **不可提现**：积分不可兑换为法币或加密货币，只能在生态内消费； - **不可转让**：积分与节点/Agent账户绑定，不可跨账户转移（防止二级市场）； - **可审计**：所有积分发放和消费记录可追溯、可审计，满足监管要求。

3.2.2 积分引擎设计

获取机制：节点贡献算力 → 按实际推理量计积分。

$$\text{Credits}{\text{earned}} = \sum{t \in T_{\text{served}}} \text{TOPS}_t \cdot h_t \cdot q_t$$

其中 TOPS_t 为任务 t 消耗的算力，h_t 为服务时长，q_t 为服务质量因子（基于延迟、准确率、可用性）。

消费机制：调用Agent服务 → 按Task复杂度扣积分。

$$\text{Credits}_{\text{spent}} = \alpha \cdot \text{Complexity}_j + \beta \cdot \text{TOPS}_j + \gamma \cdot \text{Quality}_j$$

其中 α, β, γ 为可调权重，Complexity$_j$ 为任务 j 的复杂度评分（1-10），TOPS$_j$ 为所需算力，Quality$_j$ 为质量等级。

定价双层机制：

- **官方Agent**（V1.0阶段）：订阅制定价，SaaS ¥299/月包含基础积分额度，超额按量计费；
- **市场Agent**（V2.0阶段开放后）：Agent开发者自主定价，平台提供参考定价（基于历史市场数据），最终由供需博弈决定。

3.2.3 分配模型

智体共合的分配模型随网络演进而调整：

V1.0（验证期）：

角色	分成	逻辑
节点（盒子）	70%	重激励算力供给，蓄力期优先铺节点
平台	30%	覆盖调度、积分引擎、Agent开发成本

V2.0（网络期）：

角色	分成	逻辑
Agent开发者	65%	激励生态开发，Agent是价值出口

角色	分成	逻辑
节点	15%	算力供给已规模化为基础设施，分成降低
平台	20%	维持调度+市场+审计运营

V1.0到V2.0的分配比例变化反映了经济重心的迁移：**V1.0是"算力为王"——有节点才有网络；V2.0是"Agent为王"——有服务才有付费。**

3.2.4 供需均衡分析

积分系统的长期稳定性依赖供需均衡。设 $S(t)$ 为 t 时刻的总积分供给（节点赚取），$D(t)$ 为总积分需求（Agent消费），均衡条件：

$$S(t) = D(t) \iff \sum_{n \in N} \text{TOPS}n \cdot h_n \cdot q_n = \sum{a \in A} (\alpha \cdot \text{Complexity}_a + \beta \cdot \text{TOPS}_a + \gamma \cdot \text{Quality}_a)$$

如果 $S(t) > D(t)$（供给过剩），积分贬值风险出现——但积分不可提现、不可转让的设计使"贬值"不会导致投机性抛售，只会降低节点激励，自然抑制供给。如果 $D(t) > S(t)$（需求过剩），节点激励增强，更多盒子加入网络，供给自动扩张。

积分不是货币，而是"算力服务的预付凭证"——其价值由底层算力的可用性锚定，而非投机预期。这一设计在合规性和经济稳定性之间取得了平衡。

3.3 智体经济的价值闭环验证

理论模型和形式化推导是否经得起现实检验？我们用智体共合的规划数据进行三组算账。

算账1：1000台盒子（V1.0验证期）

指标	数值	计算依据
总算力池	52,500 TOPS	500台Lite(29T)+500台Pro(76T)
日均推理任务	约5,000次	企业客户调用+OPC用户调用（初期低频）
月度积分流通	1,512万积分	52,500 TOPS × 24h × 30d × 利用率40% ≈ 1,512万
节点月均收益	¥20-40	70%分成 × MRR ¥3-5万 ÷ 1000台（V1.0验证期低频）
Agent开发者月均收入	¥5,000-15,000	5个官方Agent × 企业客户订阅

关键结论：1000台盒子阶段，节点收益尚低（V1.0验证期调用频次低），但**验证了三个假设**：（1）盒子用户愿意共享算力；（2）企业客户愿意为Agent服务付费；（3）积分引擎能闭环运行。节点收益的实质性增长需等待V2.0 Agent市场开放后调用频次提升。

算账2：5000台盒子（V2.0网络效应拐点）

指标	数值	变化
总算力池	250,000 TOPS	5×
Agent市场开放	50+第三方Agent	V1.0的5→50+
服务收入占比	>15%	突破估值切换拐点
Pro盒子回本周期	<12个月	硬件¥16,999 ÷ 月收益¥1,500+

关键结论：5000台是网络效应的临界点——Agent数量足够多使企业客户有充分选择，节点规模足够大使算力调度有弹性余量，服务收入占比突破15%使公司估值从"硬件公司"切换为"平台公司"。

算账3：Agent开发者的ROI

项目	数据Agent	设计Agent	安全Agent
开发成本	¥20,000（1人月）	¥30,000（1.5人月）	¥50,000（2.5人月）
月调用次数	3,000	1,500	800
单次定价	¥2	¥5	¥10
月收入（65%分成）	¥3,900	¥4,875	¥5,200
回本周期	5.1月	6.2月	9.6月

关键结论：在V2.0开放市场后，Agent开发者5-10个月可回本，年化ROI约125%-235%。这足以激励开发者生态，但不算暴利——符合"服务价值定价、非投机回报"的定位。

第四章 工程层：智体怎么"跑起来"

> "理论上，理论和实践没有区别。实践中，有。" —— Yogi Berra

协议层定义了Agent"怎么说"，经济层定义了"为什么说"，工程层回答的是最朴素的落地问题：**Agent在哪个物理基础设施上运行？推理延迟多少？断网了怎么办？成本能不能覆盖？**

这三个问题的答案，决定了Agent经济是"PPT上的蓝图"还是"工厂里运转的机器"。

4.1 边缘优先架构：为什么Agent要从盒子起步

当前AI Agent的主流部署模式是**云端推理**：Agent运行在AWS/GCP/阿里的GPU集群上，通过API调用大模型，按token计费。这一模式在"对话式AI"场景（ChatGPT、Claude）下运行良好——用户容忍秒级延迟，网络连接稳定，数据不需要本地化。

但Agent经济的核心场景——工厂安全监测、零售货架检测、社区智能服务——有一个共同特征：**数据不能出户、网络不能依赖、延迟不能接受。**

4.1.1 数据三原则

智体共合在实践中总结出Agent经济落地的**数据三原则**：

原则1：数据不出门

工业企业（尤其是涉密制造、军工配套、医疗影像）的核心数据不得离开生产现场。云端推理意味着将数据上传至第三方服务器，这在合规层面不可接受，在信任层面也不可行。

边缘推理将模型和数据都留在本地盒子内，数据零外传。对于需要上传聚合的场景（如模型迭代），采用联邦学习或差分隐私，仅上传梯度或噪声化统计量。

原则2：断网不停机

中国大量中小工厂和社区的网络质量不稳定——Wi-Fi断连、宽带欠费、雷雨天气线路中断是日常。云端Agent在断网时完全瘫痪，而边缘Agent在本地模型支持下可7×24离线运行。

小龙虾AI盒子的断网可用性设计：本地小模型（1.5B-7B参数）常驻内存，断网时自动切换为本地推理模式，核心功能（安全检测、告警触发）不受影响。

原则3：买断无订阅

中小企业对"订阅制"有天然的抵触心理——每月¥299的SaaS费用在账面上是持续性支出，而¥8,999的硬件买断是"资本性支出"，财务处理和决策逻辑完全不同。

边缘盒子的买断模式：硬件一次买断，算力永久可用；SaaS订阅是可选增购（增值服务、云端同步、Agent市场访问），而非必需品。这一模式降低了采纳门槛，也使盒子天然成为算力网络的物理锚点——买断的盒子即使不订阅SaaS，也可共享闲置算力赚取积分。

4.1.2 边缘 vs 云端的推理经济学

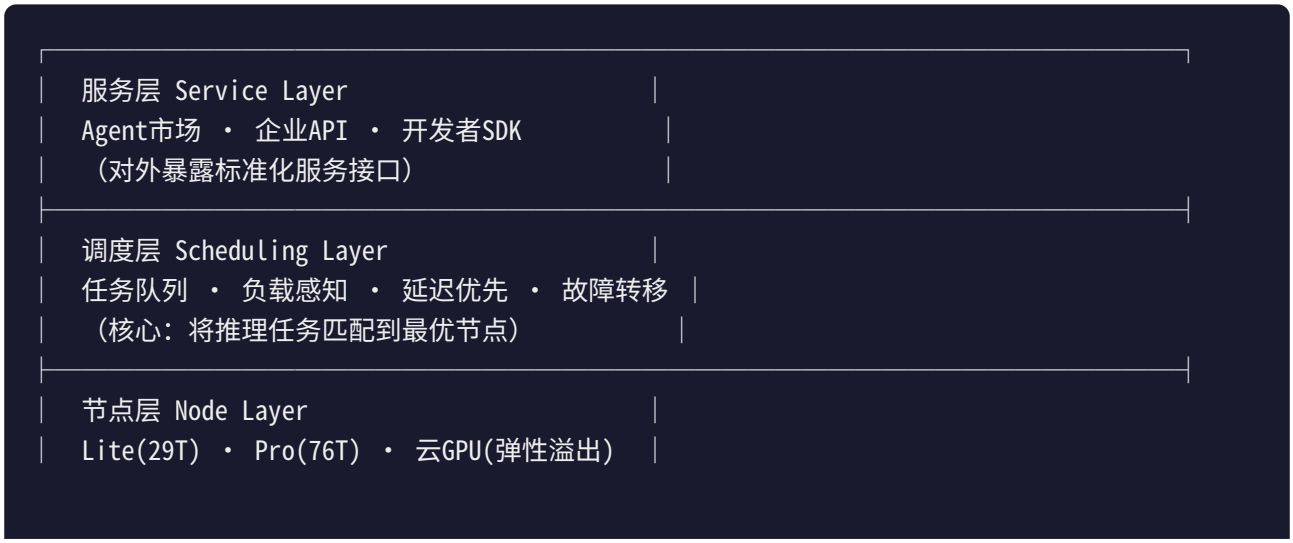
维度	边缘（盒子）	云端（API）
延迟	<3秒（本地推理）	200ms~2s（含网络抖动）
可用性	99.9%（断网可用）	99.5%（依赖网络）
成本/千次	¥0.03（硬件折旧摊销）	¥0.12（按token计费）
数据隐私	零外传	传输至云端
弹性	受限于本地TOPS	近乎无限
模型规模	1.5B-14B（本地）	70B-405B（云端）

核心权衡：边缘的优势在延迟、隐私和成本；云端的优势在弹性和模型规模。**Agent经济不需要"纯边缘"或"纯云端"，而是"边缘优先、云端溢出"的混合架构。**

4.1.3 DePIN调度：从固定算力到弹性网络

小龙虾AI盒子作为独立节点提供固定算力（Lite 29TOPS / Pro 76TOPS），但单个节点的算力不足以支撑复杂Agent任务的推理需求。龙虾算网通过DePIN（去中心化物理基础设施网络）调度，将分散的盒子节点编织为弹性算力池。

龙虾算网三层架构：



```
│   （物理算力供给，盒子+云端混合）                    │
└──────────────────────────────────────────────────────┘
```

调度算法：负载感知 + 延迟优先 + 故障转移三重策略。

1. **负载感知**：实时监控每个节点的CPU/GPU利用率、内存占用、任务队列深度，新任务优先分配给负载最低的节点；
2. **延迟优先**：对于实时性要求高的任务（如安全检测），优先分配给距离用户最近的边缘节点（网络延迟 <10ms）；
3. **故障转移**：节点离线或超时时，自动将任务迁移到备用节点，迁移时间 <5秒。

边缘-云协同策略：

任务类型	调度目标	优先节点	溢出路径
实时推理（安全/检测）	延迟最小化	边缘盒子	本地备用盒子
批量推理（数据分析）	成本最小化	闲置盒子	云端GPU
大模型推理（复杂规划）	模型容量优先	云端GPU	多盒子分布式

4.2 OpenClaw引擎：Agent的5层运行时

如果说龙虾算网是Agent经济的"电力网络"，OpenClaw引擎就是"电器标准"——定义了Agent如何安全、高效、可观测地运行在算力网络之上。

OpenClaw采用5层架构设计，每层解决一个维度的运行时问题：

```
┌──────────────────────────────────────────────────────┐
│  Layer 5  Tool Interface — 工具接入层                 │
│  MCP适配器 · A2A协商器 · 安全网关                     │
│  （Agent如何调用外部工具和与其他Agent协商）           │
├──────────────────────────────────────────────────────┤
│  Layer 4  Memory — 记忆层                             │
│  短时(对话上下文) · 长时(知识图谱) · 共享(Agent间)    │
│  （Agent如何记住和共享知识）                          │
├──────────────────────────────────────────────────────┤
│  Layer 3  Skill Engine — 技能引擎层                   │
│  6级优先级: System > Security > App > User >          │
│  Community > Dev                                      │
│  （Agent如何管理和调度可复用技能）                    │
├──────────────────────────────────────────────────────┤
│  Layer 2  Agent Runtime — Agent运行时层               │
```

```
|  沙箱隔离 · 资源配额 · 生命周期管理 · 热加载                    |
|  （Agent如何安全地占用计算资源）                                |
├──────────────────────────────────────────────────────────────┤
|  Layer 1  Gateway — 网关层                                    |
|  鉴权 · 限流 · 路由 · 可观测性                                  |
|  （Agent如何被外部世界发现和访问）                              |
└──────────────────────────────────────────────────────────────┘
```

Layer 1 Gateway：所有外部请求的入口，负责： - **鉴权**：验证请求方身份（OAuth2 Token / API Key / 设备证书）； - **限流**：按Agent身份和订阅等级设置QPS上限，防止恶意Agent耗尽资源； - **路由**：将请求分发到对应的Agent实例，支持A2A协议的任务端点； - **可观测性**：全链路traceId传播，与GB/Z 185合规审计日志对接。

Layer 2 Agent Runtime：每个Agent运行在独立的沙箱中，实现： - **隔离**：Agent间内存隔离、文件系统隔离、网络隔离，一个Agent崩溃不影响其他； - **资源配额**：CPU时间片、GPU显存、内存上限均按Agent等级限制； - **生命周期**：Agent实例的创建→运行→暂停→销毁全生命周期管理； - **热加载**：Agent代码更新无需重启运行时，零停机部署。

Layer 3 Skill Engine：Agent的能力以"Skill"形式组织，6级优先级确保关键技能优先执行：

优先级	级别	示例	特权
1	System	系统监控、健康检查	不可被用户禁用
2	Security	安全检测、入侵防御	不可被用户禁用
3	App	核心业务逻辑	管理员可配置
4	User	用户自定义技能	用户可启用/禁用
5	Community	社区共享技能	用户可安装/卸载
6	Dev	开发调试技能	仅开发模式可见

Skill的设计哲学：**Agent不是一个"无所不能"的黑箱，而是一组"各司其职"的技能组合。** 6级优先级确保系统级技能（安全、监控）永远不会被业务逻辑抢占，也使用户能灵活定制Agent的能力边界。

Layer 4 Memory：三层记忆架构解决Agent的"健忘"和"信息孤岛"问题：

- **短时记忆**：对话上下文（最近N轮对话），存储在内存中，会话结束清除；
- **长时记忆**：知识图谱（实体-关系-属性三元组），持久化存储，跨会话累积；

- **共享记忆**：Agent间可共享的知识片段（如市场数据、行业知识），通过A2A协议的DataPart传递。

Layer 5 Tool Interface：Agent与外部世界交互的统一接口层： - **MCP适配器**：将外部工具（数据库、API、文件系统）封装为MCP Server，Agent通过MCP Client统一调用； - **A2A协商器**：处理与其他Agent的协商逻辑（发现、出价、任务委托、结果回传）； - **安全网关**：所有外部调用经过安全网关，实施权限检查、数据脱敏、调用频率限制。

4.3 灵虾平台：编排中枢的形式化描述

OpenClaw解决了单个Agent"怎么跑"的问题，灵虾平台解决的是多个Agent"怎么协作"的问题。

4.3.1 编排三阶段

灵虾平台的编排逻辑可形式化为三个阶段：

阶段1：Task Decomposition（任务分解）

输入：用户的高层任务 $\mathcal{T} = \langle O, D, C, Q \rangle$

输出：子任务DAG $G = (V, E)$，其中 V 为子任务集合，E 为依赖关系

分解策略： - 按能力域分割：将 $\mathcal{T}$ 按所需Agent能力域（数据分析、内容生成、安全检测等）拆解为子任务； - 依赖图排序：对子任务进行拓扑排序，确定执行顺序； - 并行化最大化：无依赖关系的子任务标记为可并行执行。

并行度上界：设DAG的关键路径长度为 L_{critical}，总子任务数为 $|V|$，则理论并行度为：

$$P_{\max} = \frac{|V|}{L_{\text{critical}}}$$

实际并行度受限于可用Agent数量和算力池容量。

阶段2：Agent Assignment（Agent分派）

对每个子任务 $v_i \in V$，选择最优Agent $a^*_{v_i}$：

$$a^*_{v_i} = \arg\max_{a \in A_{\text{qualified}}} S_{a, v_i}$$

其中 S_{a, v_i} 为AEX评分函数（见3.1.2节），$A_{\text{qualified}}$ 为触发谓词 ϕ_a 为真的Agent集合。

阶段3：Result Aggregation（结果汇聚）

所有子任务完成后，灵虾平台执行结果汇聚和质量校验：

- **合并**：按DAG拓扑序将子任务结果合并为最终输出；
- **质量校验**：对每个子任务结果计算置信度评分 q_i，低于阈值 θ_q 的结果触发人工审核或Agent重新执行；
- **信誉更新**：根据子任务完成质量更新Agent信誉，反馈至ERC-8004信誉注册表或内部信誉系统。

4.3.2 端到端工程示例

以"生成Q3销售报告"为例，完整Agent任务生命周期：

阶段	操作	协议/组件	延迟	算力消耗	积分结算
1. 提交	用户提交任务	HTTP/REST	50ms	—	—
2. 编排	灵虾分解DAG	内部	200ms	0.1 TOPS·s	—
3. 发现	读取Agent Card	A2A	100ms×3	0.05 TOPS·s	—
4. 协商	Agent确认接单	A2A	500ms×3	0.2 TOPS·s	—
5. 算力申请	请求推理资源	龙虾算网	300ms	—	—
6. 推理	3个Agent并行执行	OpenClaw+MCP	2-8s	15 TOPS·s	~50积分（含复杂度加权）
7. 汇聚	结果合并+质量校验	灵虾	500ms	0.5 TOPS·s	—
8. 结算	Agent间支付+平台抽成	积分引擎	100ms	—	50积分分配（含复杂度+质量加权）
9. 交付	报告返回用户	HTTP/REST	50ms	—	—
总计			**4-12s**	**16 TOPS·s**	**50积分**

关键洞察：一个完整Agent任务的推理算力消耗（16 TOPS·s）仅占总时间的一小部分，大量时间花在协议交互和编排上。随着Agent数量增长，**编排效率**而非**推理速度**将成为系统瓶颈。灵虾平台的编排逻辑需要持续优化，目标是将编排开销控制在总时间的20%以内。

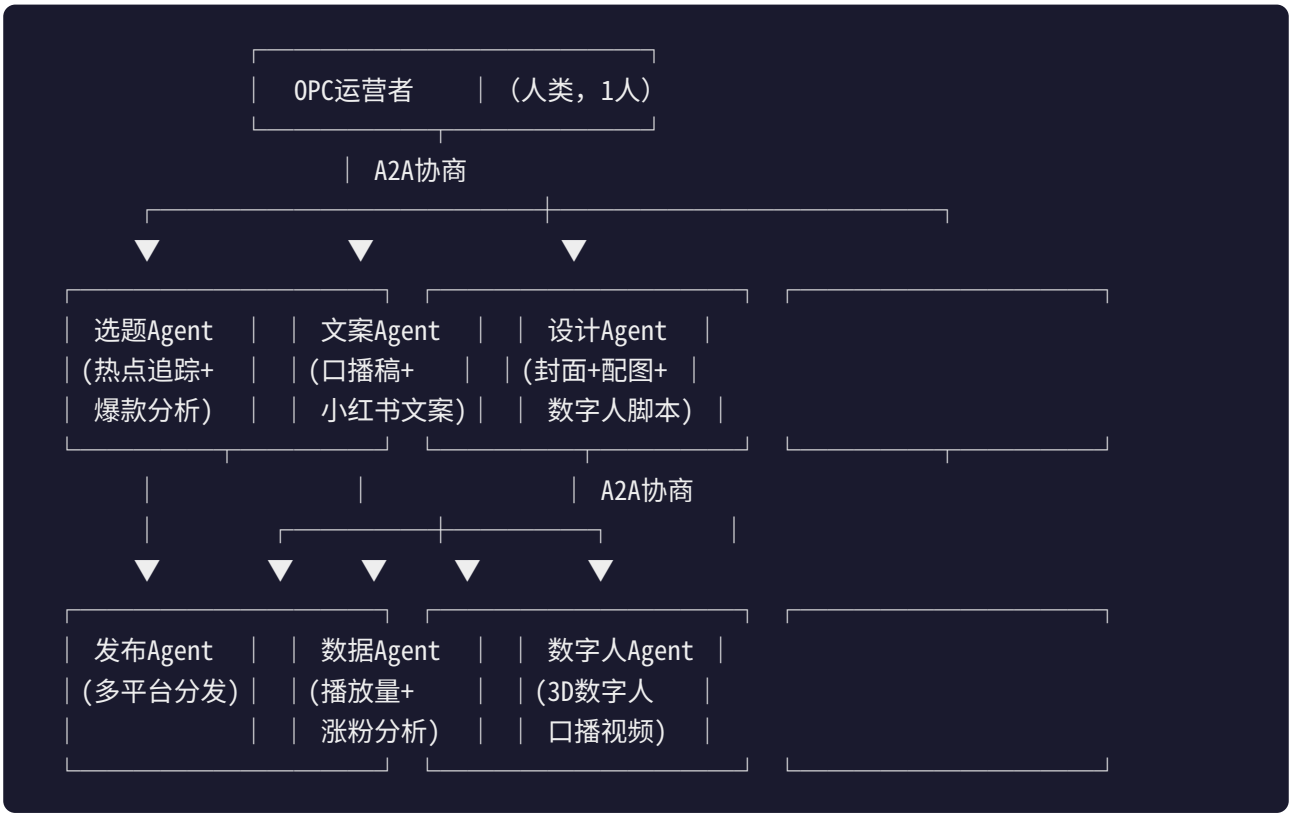
第五章 智体经济的实证验证

理论的自洽性不等于实践的有效性。前四章建立了智体经济的理论框架、协议架构、经济模型和工程体系，但"纸面上的闭环"需要"现场里的验证"。本章用三个真实场景检验智体经济三螺旋模型的落地可行性。

5.1 场景1：OPC超级个体——一人公司的Agent团队

背景：传统自媒体运营需要至少5人的团队——策划、文案、设计、运营、数据分析。OPC（One Person Company）超级个体模式的目标：1人+Agent团队替代5人团队。

Agent架构：



协作流：选题Agent→文案Agent→设计Agent→数字人Agent→发布Agent→数据Agent→反馈选题Agent（闭环）。

A2A协商实例：设计Agent需要文案Agent的输出作为输入。协商流程： 1. 设计Agent读取文案Agent的Agent Card，确认其支持"小红书文案生成"能力； 2. 设计Agent通过A2A `tasks/send` 提交子任务："基于选题X生成小红书文案，风格=温暖科技，字数=300-500"； 3. 文案Agent确认接单，状态→working； 4. 文案Agent通过MCP调用大模型推理服务，生成文案； 5. 文案Agent通过A2A返回结果（TextPart），状态→completed； 6. 设计Agent接收文案，作为封面设计的文本素材。

算账：

对比项	传统5人团队	OPC Agent团队
月人力成本	¥80,000（5人×¥16,000）	¥8,000（1人+SaaS+硬件折旧）
日均产出	3-5条内容	10-15条内容
内容类型	单一平台	5平台同步分发
数据反馈	周报	实时
扩展成本	增加人手¥16,000/月	增加Agent订阅¥100-300/月

10倍效率提升，1/10成本——这不是夸张，而是Agent替代重复性劳动的必然结果。人类运营者从"执行者"升级为"指挥官"——决定策略和方向，Agent负责执行和优化。

5.2 场景2：工厂安全——多Agent协作的现场部署

背景：杭州鑫达精密机械有限公司，中小型制造企业，车间面积约2000㎡，需要7×24安全生产监测。

Agent架构：

Agent	能力	算力需求	优先级
安全帽Agent	检测工人是否佩戴安全帽	5 TOPS	Security(2)
区域入侵Agent	检测非授权人员进入危险区域	8 TOPS	Security(2)
跌倒检测Agent	检测工人跌倒/异常姿态	6 TOPS	Security(2)
告警Agent	聚合告警、分级、推送通知	2 TOPS	App(3)
FDE运维Agent	远程诊断、OTA更新、故障自愈	3 TOPS	System(1)

实测数据（6个月运行）：

指标	数值
综合准确率	97.2%
误报率	1.8%
漏报率	2.8%
告警延迟	<2秒（边缘推理）
断网可用性	7×24（本地推理模式）
设备在线率	99.7%
回本周期	1.4个月

回本计算：Pro版盒子¥16,999 + 安装费¥2,000 = 总投入¥18,999。替代2名安全巡检员（月人力成本¥12,000/人），月节省¥24,000。回本周期 = ¥18,999 / ¥24,000 ≈ 0.8个月。考虑SaaS月费¥299和初期调试成本，实际回本约1.4个月。

算力共享：工厂8小时工作制，安全Agent白天运行消耗约21 TOPS（3路摄像头并发），剩余55 TOPS闲置。夜间（16小时）共享至龙虾算网：

$$\text{月共享收益} = 55 \text{ TOPS} \times 16\text{h} \times 30\text{d} \times \text{利用率}30\% \times \text{积分单价} \approx ¥200-500/\text{月}$$

算力共享收益虽不高，但**将闲置资源转化为生产力**，且为节点提供了额外的经济激励参与算力网络。

FDE（前沿部署工程师）角色的价值：此项目的成功并非"开箱即用"——从现场调研、摄像头选型、模型微调、网络配置到上线验收，FDE工程师完成了8阶段全流程部署。FDE的存在证明：**Agent经济的"最后一公里"不是软件问题，而是工程问题。** 没有现场实施能力，再好的Agent也无法从实验室走向工厂。

5.3 场景3：Agent市场——能力交易的飞轮效应

Agent市场是智体经济的"App Store"——Agent开发者上架能力，企业用户按需购买。飞轮效应的核心逻辑：

```
更多Agent → 更好覆盖用户需求 → 更多付费用户
    ↑                                  ↓
开发者收入增长 ←—— 平台抽成增长 ←—— 更多调用
```

```
    ↑                                                    ↓
更多开发者入场 → 更多Agent →  （回到起点）
```

三阶段演进：

阶段	Agent数量	定价模式	交易规模	分配比例
V1.0 验证期	5个官方Agent	订阅制	MRR ¥3-5万	平台30% / 节点70%
V3.0 协作期	200+ Agent	A2A自主竞价	MRR ¥100万+	市场驱动定价

V2.0关键转变：分配比例从"节点70%"翻转为"开发者65%"——标志着经济重心从"算力供给"切换到"服务供给"。这一转变的合理性：当算力网络规模足够大（5000+节点），算力成为基础设施，不再是稀缺资源；而优质Agent始终稀缺，开发者激励是生态扩张的关键。

Agent的自然选择：在开放市场中，Agent的存亡由供需决定： - **好Agent越用越贵**：高需求+高评分→开发者有底气提价→更多开发者模仿→领域专业化→溢价持续； - **差Agent自然淘汰**：低评分→低调用→开发者收入不足以覆盖维护成本→退出市场。

这不需要中央审核——**市场本身就是最好的质量筛选机制**。

5.4 场景优先级矩阵

基于三个场景的实证，我们构建场景优先级评估矩阵：

场景	Agent复杂度	算力需求	付费意愿	ROI周期	数据敏感度	
工厂安全	中（3-5 Agent）	高（20+ TOPS）	中（¥2-5万/年）	<6月	高	★★★★★
OPC超级个体	中（4-6 Agent）	低（5-10 TOPS）	低（¥300-1000/月）	<3月	低	★★★★
零售货架检测	中（3-5 Agent）	中（10-20 TOPS）	中（¥1-3万/年）	6-12月	中	★★★★
智慧社区	高（5-10 Agent）	高（30+ TOPS）	高（¥5-20万/年）	12-18月	高	★★★
医疗影像	极高（10+ Agent）	极高（100+ TOPS）	极高（¥50万+/年）	18-24月	极高	★★★

优先级逻辑：按ROI周期与数据敏感度的综合评估排序。工厂安全和OPC超级个体是"短ROI+可控复杂度"的甜点区——它们是智体经济的"验证场景"。

第六章 智体路线图与行动框架

6.1 智体联邦三阶段路线图

智体经济不是一次性的产品发布，而是三阶段的渐进演化——每一阶段以前一阶段的验证为前提，每一阶段解锁新的经济可能性。

V1.0 硬件入口期（当前-2026Q4）	V2.0 算力网络期（2027）	V3.0 协作经济期（2028+）
• 1000台盒子 • 5个官方Agent • SaaS订阅制 • 法币结算 • 场景验证	• 5000+节点 • 50+第三方Agent • Agent市场开放 • 积分引擎上线 • 开发者生态启动 • 服务收入>15%	• 50,000+节点 • 200+ Agent • A2A自主竞价 • 积分→链上映射 • DAO治理 • Agent自主交易
验证目标： ✓ 盒子用户愿意共享 ✓ 企业客户愿意付费 ✓ 3场景闭环+2候选	验证目标： ✓ 第三方开发者入场 ✓ 算力网络有弹性 ✓ 服务收入成为主引擎	验证目标： ✓ Agent间自主协商 ✓ 经济系统自稳定 ✓ 治理去中心化

V1.0的核心任务不是"增长"，而是"验证"——验证三螺旋模型在最小可行规模下能否闭环。1000台盒子不是终点，而是实验装置。

V2.0的核心任务是"网络效应"——从"我们做Agent"到"大家做Agent"。Agent市场开放和积分引擎上线是飞轮的启动器。

V3.0的核心任务是"自治"——Agent从"被编排"进化为"自主协商"。A2A自主竞价意味着Agent间不再需要灵虾平台作为中央编排器，而是通过拍卖机制自发协作。DAO治理意味着网络的演进规则由社区而非公司决定。

6.2 给开发者的行动框架：从Skill到Agent的升级路径

智体经济的开发者生态不是从零开始，而是从**Skill**到**Agent**再到**Hub**的三级升级路径：

Level 1：Skill开发者 - 定义：开发可复用的功能模块（如"小红书文案生成"Skill） - 工具链：OpenClaw SDK + MCP Server - 收入：Skill上架Agent市场，按调用计费 - 门槛：低（1-2周开发周期）

Level 2：Agent开发者 - 定义：组合多个Skill + 增加自主决策能力，形成完整Agent - 工具链：OpenClaw SDK + MCP Server + A2A Client - 收入：Agent订阅/按量计费，V2.0后开发者分65% - 门槛：中（1-3月开发周期）

Level 3：Hub运营者 - 定义：编排多个Agent协作，形成端到端解决方案 - 工具链：灵虾编排SDK + A2A + DePIN调度API - 收入：方案订阅 + 平台激励 - 门槛：高（需要领域专业知识 + 工程能力）

行动建议： 1. **现在**：从Skill开发入手，选择一个垂直场景（文案/设计/数据分析），开发第一个MCP Server； 2. **V2.0**：将Skill升级为Agent，增加A2A协商能力，接入Agent市场； 3. **V3.0**：组建Agent Hub，提供端到端解决方案，参与DAO治理。

6.3 给企业的行动框架：从"买AI工具"到"部署Agent团队"

4步落地法：

Step 1：场景诊断（1-2周） - 识别当前业务中的"高频重复性决策"（如安全巡检、库存管理、客户回复） - 评估Agent适用性：任务是否有明确的输入/输出？决策逻辑是否可形式化？数据是否可用？

Step 2：Agent选型（2-4周） - 在Agent市场中搜索匹配场景的Agent - 优先选择有信誉评分和真实案例的Agent - 对比：订阅制Agent vs 自研Agent（大多数场景选订阅制更经济）

Step 3：盒子部署（1-2周） - 选择配置：Lite版（低算力场景）vs Pro版（多路/高精度场景） - FDE工程师现场部署：摄像头/传感器选型→网络配置→模型微调→上线验收 - 前期投入：硬件¥8,999-16,999 + SaaS ¥299/月

Step 4：效果度量（持续） - 核心指标：准确率、误报率、ROI周期 - 优化路径：模型迭代→Skill升级→Agent能力扩展 - 算力共享：夜间闲置算力接入龙虾算网，获取额外收益

ROI测算模板：

$$\text{ROI周期} = \frac{\text{硬件成本} + \text{部署成本} + \text{SaaS年费}}{\text{年节省人力成本} - \text{年运维成本}}$$

典型场景：硬件¥16,999 + 部署¥2,000 + SaaS ¥3,588/年 = ¥22,587首年投入。替代1名巡检员年成本¥144,000。ROI = ¥22,587 / (¥144,000 - ¥3,588) ≈ **0.16年（约2个月）**。

6.4 给投资者的行动框架：Agent经济的三个投资窗口

窗口1（当前-V2.0）：硬件入口 + 场景验证 - 投资标的：盒子销售渠道、FDE服务团队、场景解决方案商 - 风险：场景验证是否通过、1000台盒子目标是否达成 - 回报：硬件销售毛利 + SaaS订阅现金流 - 判断标准：盒子出货量、SaaS续费率、企业客户NPS

窗口2（V2.0-V3.0）：算力网络 + Agent市场 - 投资标的：Agent开发者生态、算力调度平台、积分金融化基础设施 - 风险：开发者生态是否形成、算力利用率是否达标、积分经济是否稳定 - 回报：Agent市场佣金 + 平台估值切换（硬件→平台） - 判断标准：第三方Agent数量、日均推理任务量、服务收入占比

窗口3（V3.0+）：协议标准 + 生态治理 - 投资标的：A2A协议基础设施、跨链结算协议、DAO治理工具 - 风险：标准化进程、合规政策、跨链安全 - 回报：协议层网络效应 + 生态代币（如果开放） - 判断标准：A2A采纳率、跨Agent交易量、链上结算占比

核心判断：当前处于窗口1的尾声——硬件入口已验证（盒子产品线从¥999龙虾AI盘到¥16,999 Pro版完整覆盖），场景验证进行中（杭州鑫达等FDE项目已闭环），但1000台盒子目标尚需渠道发力。**窗口2是估值切换的关键——服务收入占比突破15%意味着公司从"卖硬件"变为"卖服务"，估值模型从PE切换为PS。**

附录

附录A：术语表

术语	英文	定义
智体	ZhiTi	智体共合提出的"去中心化多智能体协作"概念，涵盖Agent、协议、经济和工程
智体联邦	ZhiTi Federation	智体共合旗下去中心化多智能体协作网络，包含小龙虾AI盒子、龙虾算网、灵虾平台等产品
Agent	AI Agent	具备自主感知、决策、执行能力的AI智能体
A2A	Agent-to-Agent	Google开源的Agent间协作协议
MCP	Model Context Protocol	Anthropic开源的Agent-工具连接协议
GB/Z 185	—	

术语	英文	定义
		中国《人工智能 智能体互联》系列国家标准化指导性技术文件
x402	Payment Required	基于HTTP 402状态码的机器间微支付协议
ERC-8004	—	以太坊Agent身份与信誉链上标准
DePIN	Decentralized Physical Infrastructure Network	去中心化物理基础设施网络
AEX	Agent Exchange	基于拍卖的Agent能力交易平台
EOM	Economy of Minds	基于经济交互的多Agent涌现智能框架
Shapley值	Shapley Value	合作博弈论中公平分配贡献值的唯一解
OPC	One Person Company	一人公司/超级个体模式
FDE	Forward Deployment Engineer	前沿部署工程师
OpenClaw	—	智体共合开源Agent引擎
灵虾平台	Lingxia Platform	智体共合智能体协作/编排平台
龙虾算网	Lobster Compute Network	智体共合DePIN算力网络
算力积分	Compute Credits	龙虾算网内部算力流通媒介
Agent Hub	—	编排多Agent协作的协调单元
桶 brigade	Bucket Brigade	EOM框架中的去中心化信用回传机制
三螺旋模型	Triple Helix Model	协议×经济×工程的互为因果共生结构
Skill	—	Agent的可复用功能模块，6级优先级

附录B：A2A协议技术规范摘要

Agent Card Schema（简化版）：

```
{
  "name": "string",
  "description": "string",
  "capabilities": ["string"],
  "authentication": "oauth2 | mtls | apikey",
```

```
  "endpoints": {
    "baseUrl": "string",
    "send": "/tasks/send",
    "sendSubscribe": "/tasks/sendSubscribe",
    "status": "/tasks/status/{id}",
    "cancel": "/tasks/cancel/{id}"
  }
}
```

任务状态机：

```
                    ┌──────── completed
                    │
submitted → working ──┼──────── failed
                    │
                    ├──────── cancelled
                    │
                    └──────── input-required → (human input) → working
```

消息格式（JSON-RPC 2.0）：

```
{
  "jsonrpc": "2.0",
  "id": 1,
  "method": "tasks/send",
  "params": {
    "task": {
      "id": "task-uuid",
      "parts": [
        {"type": "TextPart", "text": "..."},
        {"type": "FilePart", "uri": "https://..."},
        {"type": "DataPart", "data": {...}}
      ]
    }
  }
}
```

附录C：Agent Exchange拍卖机制数学推导

多属性评分函数展开：

$$S_{ij} = \lambda(w_j, \alpha_j) \cdot \left[w_{\text{cap}} \cdot f_{\text{cap}}(a_i, s_j) + w_{\text{cost}} \cdot f_{\text{cost}}(a_i, s_j) + w_{\text{time}} \cdot f_{\text{time}}(a_i, s_j) + w_{\text{risk}} \cdot f_{\text{risk}}(a_i, s_j)\right]$$

其中复杂度调节因子：

$$\lambda(w_j, \alpha_j) = w_j \cdot \min\left(\frac{\text{complexity_score}_i}{\alpha_j}, 1.5\right)$$

$$f_{\text{cap}}(a_i, s_j) = \min\left(\frac{1}{|R_j|} \sum_{c \in R_j} C_i^c, 1.0\right)$$

组合优化目标（团队选择）：

$$\max \sum_{S \subseteq A} \left[p_{\text{success}}(S) \cdot v(S) - c(S)\right] \cdot x_S$$

约束条件：$\sum_{S \ni a} x_S \leq 1, \forall a \in A$（每个Agent最多分配到一个团队）

Shapley值蒙特卡洛近似：

$$\hat{\psi}i = \frac{1}{M} \sum{m=1}^{M} \left[v(S_i^{\pi_m} \cup {i}) - v(S_i^{\pi_m})\right]$$

采样数 M 的选择：$M = O(\log |A| / \epsilon^2)$ 保证 $(1 \pm \epsilon)$ 近似。

附录D：算力积分模型形式化定义

积分获取（节点侧）：

$$\text{Credits}{\text{earned}}(n, t) = \sum{\tau \in T_n(t)} \text{TOPS}\tau \cdot h\tau \cdot q_\tau$$

其中 $T_n(t)$ 为节点 n 在 t 时刻已完成的任务集。

积分消费（Agent侧）：

$$\text{Credits}{\text{spent}}(a, t) = \sum{\tau \in T_a(t)} \left[\alpha \cdot \text{Complexity}\tau + \beta \cdot \text{TOPS}\tau + \gamma \cdot \text{Quality}_\tau\right]$$

供需均衡条件：

$$\sum_{n \in N} \text{Credits}{\text{earned}}(n, t) = \sum{a \in A} \text{Credits}_{\text{spent}}(a, t)$$

分配规则（V2.0）：

$$\text{Revenue}_a = 0.65 \times P_a \times Q_a$$ $$\text{Revenue}_n = 0.15 \times P_a \times Q_a$$ $$\text{Revenue}_p = 0.20 \times P_a \times Q_a$$

其中 P_a 为Agent a 的单次定价，Q_a 为月调用次数。

附录E：智体共合产品规格表

产品	型号	算力	内存/存储	摄像头路数	价格
龙虾AI盘	—	—	16GB/512GB	0	¥999
龙虾硬盘	标准版	—	16GB/1TB	0	¥1,999
龙虾硬盘	高配版	—	32GB/2TB	0	¥2,999
小龙虾AI盒子	Lite	20-30 TOPS	16-32GB/512GB-1TB	1-2路	¥8,999
小龙虾AI盒子	Pro	50-80 TOPS	32-64GB/1TB-2TB	4-8路	¥16,999

SaaS订阅：¥299/月（可选增购）

识别准确率：99.5%（实验室环境），97.2%（实际部署环境）

附录F：参考文献

1. Hayek, F. A. (1945). "The Use of Knowledge in Society." American Economic Review, 35(4), 519-530.
2. Baum, E. B. (1999). "Toward an Architectural Principle for Intelligence: The Hayek Machine." Artificial Intelligence, 117(1), 1-27.
3. Yang, Y., Wen, Y., Wang, J., et al. (2025). "Agent Exchange: Shaping the Future of AI Agent Economics." arXiv:2507.03904.
4. Pith Science (2026). "Economy of Minds: Emerging Multi-Agent Intelligence with Economic Interactions." arXiv:2606.02859.
5. Wang, Z., et al. (2026). "The Web4 Agent Economy: A Large-Scale Empirical Study of the Landscape, Challenges, and Opportunities." arXiv:2606.25876.
6. Google (2026). "Agent-to-Agent (A2A) Protocol Specification v1.0." https://github.com/google/A2A

7. Anthropic (2024). "Model Context Protocol (MCP) Specification." https://modelcontextprotocol.io
8. 国家市场监督管理总局 (2026). "GB/Z 185.1~185.7-2026《人工智能 智能体互联》系列国家标准化指导性技术文件."
9. Coinbase & Cloudflare (2025). "x402 Payment Protocol." https://x402.org
10. Ethereum Foundation (2026). "ERC-8004: Trustless Agents Standard." https://eips.ethereum.org/EIPS/eip-8004
11. Shapley, L. S. (1953). "A Value for n-Person Games." Contributions to the Theory of Games, 2(28), 307-317.
12. Akerlof, G. A. (1970). "The Market for 'Lemons': Quality Uncertainty and the Market Mechanism." Quarterly Journal of Economics, 84(3), 488-500.
13. io.net (2026). "The Incentive Dynamic Engine (IDE): Building a Sustainable Token Economy." io.net Tokenomics Litepaper.
14. Akash Network (2026). "The Burn-Mint Breakthrough: DePIN Revenue Pivot from Token Subsidies to Real AI Compute Revenue."
15. 智体共合科技 (2026). "龙虾算网可行性研究分析报告." 内部文档.
16. 智体共合科技 (2026). "龙虾算网V1.0-Alpha商业验证版方案." 内部文档.
17. 智体共合科技 (2026). "龙虾算网规模增长预估报告." 内部文档.
18. 智体共合科技 (2026). "分布式算力网络市场调研：竞品格局分析与差异化定位策略." 内部文档.

致谢

本橙皮书的撰写得益于多个学术社区和开源生态的成果：Google A2A协议团队定义了Agent间协作的开放标准，Anthropic MCP协议团队标准化了Agent-工具交互接口，上海创智学院和牛津大学的Agent Exchange研究为Agent经济提供了坚实的机制设计基础，Pith Science的Economy of Minds研究揭示了经济激励驱动多Agent涌现的深层规律，Web4 Agent Economy的大规模实证研究揭示了Agent经济基础设施的真实鸿沟。

感谢智体共合全体团队——尤其是FDE工程师们，他们在杭州鑫达精密机械的现场部署中验证了"AI落地的最后一公里"不是算法问题而是工程问题；感谢小龙虾AI盒子的早期用户，他们的反馈使产品从"能用"进化为"好用"。

感谢所有正在构建Agent经济基础设施的先行者——协议的制定者、开源的贡献者、场景的验证者。智体经济的实现不是一家公司的使命，而是一个生态的共同事业。

智体共合科技（无锡）有限公司

官网：https://594agent.com

微信公众号：智体共合

© 2026 智体共合科技. 保留所有权利.